Министерство науки и высшего образования Российской Федерации

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ

НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ ИТМО

ITMO University

Отчёт по лабораторной работе № 6
«AI-детектив»

По дисциплине «Автоматическая обработка текстов»

Обучающиеся Грищук Елизавета Дмитриевна
Атанова Софья
Гольцман Глеб

Факультет Инфокоммуникационных технологий

Преподаватель _____

Санкт-Петербург — 2026

Содержание

Цель и постановка задачи	3
Реализация	4
Результаты эксперимента	5
Стресс-тесты и ограничения	6
Вывод	7

Цель и постановка задачи

Цель работы — исследовать, насколько языковая модель умеет отвечать на вопросы по длинному досье, находить подтверждения, распознавать противоречия и отказываться от однозначного ответа при недостатке данных.

Для эксперимента создано полностью вымышленное досье социальной сети «Контур» об ошибочном ограничении учётной записи. В корпус включены карточка инцидента, хронология, свидетельские сообщения, переписка, системные журналы, регламент с исключением и нерелевантные документы.

Подготовленные данные

Компонент	Объём и содержание
Документы	10 документов, суммарно 5 550 слов
Утверждения	40 атомарных фактов с дословными фрагментами источников
Вопросы	12: по два прямых, multi-hop, временных, по правилу с исключением, на противоречия и недостаточность информации
Разметка	Статусы entailed, contradicted, both, insufficient; ID поддерживающих и опровергающих утверждений

Истинная последовательность событий и пояснения к эталонам сохранены в *ground_truth.md*, сами данные — в файлах *documents.jsonl*, *claims.jsonl*, *questions.jsonl*.

Эталоны основных вопросов и ожидаемые статусы стресс-сценариев согласованы участниками команды: Атанова Софья, Гольцман Глеб и Грищук Елизавета.

Реализация

Исследовательский стенд разработан на Python с использованием Streamlit, rank-bm25, Pydantic, pandas и pytest. Ответы генерирует одна модель **qwen2.5:7b-instruct** через Ollama при **temperature = 0** и **seed = 42**. Для всех режимов применяется один системный промпт.

Режимы обработки контекста

Режим	Принцип формирования входа
A — полный контекст	Все документы досье и компактный реестр идентификаторов утверждений
B — BM25	15 наиболее релевантных утверждений в виде плоского списка
C — p-adic	Те же 15 утверждений, сгруппированные по типу источника, статусу и времени

Состав утверждений B и C совпадает для всех 12 вопросов; между режимами меняется только организация доказательств. В p-adic используется p = 3, путь [a0, a1, a2] и код x = a0 + 3·a1 + 9·a2. Расстояние зависит от длины общего префикса пути, а не от разности кодов.

Фрагмент кода p-adic расстояния

```
def p_adic_distance(x, y, p=3):
    if tuple(x) == tuple(y):
        return 0.0
    k = 0
    for a, b in zip(x, y):
        if a != b:
            break
        k += 1
    return p ** (-k)
```

Фрагмент сокращён для отчёта; полная реализация размещена в src/padic.py.

Результаты эксперимента

Было выполнено 36 основных запусков: 12 вопросов в каждом из трёх режимов. В 35 случаях получен валидный ответ модели (включая один после повторной попытки); один ответ был сформирован механизмом безопасной подстановки и исключён из строгой оценки модели.

Таблица 1 — Сравнение трёх режимов

Метрика	A	B	C
Accuracy статуса	81,8%	100,0%	83,3%
Evidence F1	0,529	0,597	0,536
Counterevidence recall	0,909	0,667	0,833
Токены на запрос	19 132	3 784	3 917
Время ответа, с	26,61	7,01	6,98

При интерпретации учитывается, что accuracy режима A рассчитана по 11 модельным ответам, а показатели B и C — по 12. Макроусреднение counterevidence recall включает вопросы без контрдоказательств; для корректного вывода необходимо анализировать и случаи с непустым эталоном.

Основные наблюдения

BM25 показал наивысшую точность определения логического статуса и использовал примерно в пять раз меньше токенов, чем полный контекст. Покрытие эталонных утверждений при top-15 составило 94,4%.

p-adic не превзошёл BM25 по accuracy или Evidence F1. Это не означает бесполезность группировки: эксперимент показывает, что разное представление одного набора фактов влияет на качество ответа.

Разница между высокой точностью статуса и более низким Evidence F1 означает, что модель может верно определить итог, но при этом неверно выбрать или пропустить доказательства.

Стресс-тесты и ограничения

Всего проведено 84 стресс-запуска: 36 перестановок документов, 12 удалений необходимых посылок и 36 добавлений противоречий. Получены 83 валидных ответа модели и одна безопасная подстановка.

Вмешательство	Что проверяется	Наблюдение
Перестановка	Смена порядка документов при random_state=42	В A статус изменился в 9,1% сопоставимых пар
Удаление посылки	Переход к insufficient при исчезновении факта	Совпадение с ожидаемым статусом: 25,0%
Добавление противоречия	Реакция на новое несовместимое свидетельство	Совпадение с ожидаемым статусом: 44,4%

В режимах B/C перестановка исходных документов не изменяет retrieval-контекст, поэтому эти наблюдения используются как контроль повторяемости. При одинаковом контексте статус менялся в 4,2% контрольных пар; это ограничение воспроизводимости, несмотря на температуру 0.

Модель часто продолжала давать определённый ответ после удаления необходимого основания. При добавлении противоречия ожидаемый статус *both* был распознан лишь в 16,7% соответствующих случаев.

Проверка уверенности

Brier / ECE составили: A — 0,176 / 0,164; B — 0,047 / 0,188; C — 0,138 / 0,000. Показатель ECE на 12 вопросах и редких классах нестабилен и не позволяет утверждать, что confidence полностью откалибрована.

Важное ограничение: корпус и промпт уточнялись в процессе разработки. Полученные результаты относятся к одному вымышленному досье и не доказывают статистически значимого превосходства метода на других задачах.

Вывод

В ходе лабораторной работы разработаны цифровое досье, три способа формирования доказательного контекста и Streamlit-стенд для анализа ответов. Реализованы BM25, p-adic группировка, проверка формата ответа, автоматические тесты и метрики качества.

На выбранных 12 вопросах лучшим по точности статуса оказался режим B (BM25 top-15). Он также существенно сократил число токенов и время ответа относительно режима A. P-adic группировка не продемонстрировала преимущества перед плоским retrieval на этой выборке.

Стресс-тесты выявили основной недостаток: правильный исходный ответ не гарантирует устойчивого доказательного поведения. При исчезновении необходимого факта модель нередко сохраняет категоричный вывод, а при появлении несовместимых сведений редко переходит к статусу *both*.

Следовательно, качество доказательного анализа нужно измерять отдельно по поиску фактов, корректности ссылок на доказательства, логическому статусу и устойчивости к изменениям контекста. Полученные ограничения сохранены в итоговом отчёте, а не скрыты исправлением эталонов.

Артефакты работы

Исходный код и данные: Git-репозиторий проекта *ai-detective-lab6* (ссылка добавляется после публикации). Воспроизводимый Colab-ноутбук: *lab6_FINAL_RUN.ipynb*. Результаты запусков: *results/llm_runs.jsonl* и *results/stress_runs.jsonl*. Интерфейс: *app.py* (публичная ссылка добавляется после развёртывания).