Министерство науки и высшего образования Российской Федерации
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ ИТМО
ITMO University

Отчет по лабораторной работе № 6

По дисциплине Автоматическая обработка текста

Обучающийся Грищук Елизавета, Гольцман Глеб, Атанова Софья

Факультет факультет инфокоммуникационных технологий

Группа К3243

Направление подготовки 45.03.04 Интеллектуальные системы в гуманитарной сфере

Образовательная программа Интеллектуальные системы в гуманитарной сфере

1. Цель и постановка задачи

В этой работе мы исследовали, насколько одна языковая модель умеет отвечать на вопросы по длинному досье и подтверждать выводы конкретными фрагментами источников. Нас интересовала не только правильность ответа, но и то, какие доказательства выбраны, как модель обрабатывает противоречия, временные связи и нехватку сведений. Мы сравнили три способа передачи контекста и провели стресс-тесты, изменяя по одному фактору.

2. Подготовка досье и эталонов

Мы создали вымышленный кейс о блокировке учётной записи в социальной сети «Контур». Досье содержит **10 документов** объёмом около **5 550 слов**: карточку инцидента, временную шкалу, сообщения участников, переписку, системный журнал, регламент с исключением и два отвлекающих документа. Истинную последовательность событий мы отдельно записали в ground_truth.md, чтобы не подстраивать эталоны под ответы модели.

Из документов выделили **40 атомарных утверждений** (claims.jsonl). Для каждого сохранили claim_id, ссылку на документ, статус источника и дословную цитату evidence. Проверили уникальность идентификаторов, наличие документов и совпадение цитат с исходным текстом. Утверждения имеют статусы direct, reported и disputed; формат также допускает inferred.

Мы подготовили **12 вопросов**, по два каждого типа: прямые, multi-hop, временные, правило с исключением, противоречия и недостаточность информации. Для каждого определили эталонный ответ, логический статус и ID доказательств и контрдоказательств. Возможные статусы: entailed, contradicted, both, insufficient. В исходных эталонах соответственно 6, 3, 1 и 2 вопроса. Эталоны нужно проверять независимо от модели; именно они служат основой оценки.

3. Методика сравнения

Во всех экспериментах использовали **Qwen2.5-7B-Instruct** через Ollama в Google Colab. Сохранили один системный промпт и одинаковые параметры: temperature=0, seed=42, размер контекстного окна 32 768 токенов. Модель выдавала структурированный JSON: вопрос, статус, краткий ответ, evidence_ids, counterevidence_ids, confidence от 0 до 1 и объяснение. Pydantic и дополнительные проверки обнаруживали некорректные поля и несуществующие ID.

Режим A передавал все документы вместе с реестром идентификаторов. **Режим B** использовал BM25 и выбирал 15 наиболее подходящих утверждений; они передавались плоским списком. **Режим C** получал ровно те же 15 ID, но группировал их по p-adic ветвям и упорядочивал внутри ветвей по времени. Совпадение составов B и C проверено для каждого вопроса.

Для p-adic организации приняли p=3. Путь [a0,a1,a2] кодирует тип источника, логический статус и временную категорию. Расстояние определяется длиной общего начального префикса: при k совпадающих уровнях d3=3^(-k), а при одинаковых путях расстояние равно нулю. Мы намеренно не использовали обычную разность числовых кодов. Тип источника поставили первым: для проверки фактов надёжность источника важнее близости событий по времени. При другом порядке уровней ветви группировались бы иначе, но этот вариант отдельно не тестировался.

4. Основной эксперимент

Мы выполнили **36 запросов**: 12 вопросов в трёх режимах. Результаты, точные контексты и метрики сохранили в results/. Из 36 ответов **35 прошли строгую валидацию модели**, один случай завершился безопасной подстановкой (safe_fallback). Метрики ниже относятся к валидным модельным ответам, без подстановки.

Режим	Accuracy статуса	Evidence F1	Counter recall	Средние токены	Время, с
A — весь текст	81,8%	0,529	0,909	19 132	26,61
B — BM25	100,0%	0,597	0,667	3 784	7,01
C — p-adic	83,3%	0,536	0,833	3 917	6,98

В нашем запуске **режим B оказался лучшим по accuracy статуса и Evidence F1**. По сравнению с A он использовал значительно меньше токенов и отвечал быстрее. BM25 покрывал в среднем **94,4% эталонных утверждений**, поэтому сокращение контекста не привело к заметной потере ключевых фактов. При этом совпадение статуса с эталоном не гарантировало качественного обоснования: значения Evidence F1 во всех режимах существенно ниже accuracy. Результат C не подтвердил гипотезу об обязательной пользе p-adic группировки.

5. Стресс-тестирование

Дополнительно мы сохранили **84 стресс-прогона**: 36 перестановок, 12 удалений посылки и 36 добавлений противоречия. Каждое изменение фиксировали вместе с входным контекстом и ожидаемым статусом. Из 84 стресс-ответов **83 были валидными ответами модели**, один — безопасной подстановкой.

Вмешательство	Объём	Основное наблюдение
Перестановка документов, seed 42	36	В A статус изменился у 9,1% сопоставимых валидных пар; B/C использовались как контроль одинакового retrieval-контекста
Удаление необходимой посылки, Q03–Q06	12	Только 25,0% ответов совпали с ожидаемым статусом
Добавление подготовленного противоречия	36	Совпадение с ожидаемым статусом — 44,4%; распознавание both там, где оно ожидалось, — 16,7%

Перестановка меняла порядок **документов**, а не список утверждений. Для B/C после отбора сохранялся прежний набор: 24 повтора на одинаковом контексте позволили увидеть собственную вариативность генерации. В этих контролях статус менялся в 4,2% случаев.

Удаление посылки проверяло, способен ли ответ стать insufficient, когда исчезает необходимое основание. Например, для Q03 в одном из стресс-прогонов ожидается insufficient, но модель продолжила отвечать entailed. Добавление несовместимого утверждения проверяло распознавание конфликтующих источников; в ряде случаев модель игнорировала новую запись и сохраняла прежнюю уверенную метку. Такие ошибки мы оставили в итоговых результатах, а не исправляли вручную.

6. Confidence, интерфейс и проверка

Мы отдельно рассмотрели уверенность модели. Brier score составил **0,176** в A, **0,047** в B и **0,138** в C. Однако при двух эталонных вопросах insufficient и одной исходной ситуации both выводы о калибровке и редких классах ограничены. В C встречались уверенные ошибки на недостаточных данных; поэтому высокий confidence нельзя считать доказательством правильности.

Для демонстрации сделали Streamlit-стенд. Он загружает досье, позволяет выбрать вопрос и режим, показывает ответ и confidence, тексты доказательств и контрдоказательств, применяет три реальные операции над контекстом, отображает p-adic ветви и сравнивает архивные результаты A/B/C. **Прямого вызова модели из интерфейса нет**: эксперименты запускались в Colab. Для изменённого контекста стенд показывает сохранённый ответ только тогда, когда совпадает его **SHA-256**; для произвольного изменения честно сообщает об отсутствии экспериментального ответа.

Код проверяли с помощью pytest: проверяются JSON-схемы, связи документов и утверждений, BM25 top-15, совпадение B/C, свойства p-adic расстояния, вмешательства и обработка некорректных ответов. Решения, предложенные ИИ-ассистентом, пересматривали вручную; ключевые исправления зафиксированы в AI_LOG.md.

7. Примеры из полученных ответов

Мы отдельно посмотрели несколько показательных случаев. Эти примеры помогают понять, что именно означает правильная метка и почему одного процента accuracy недостаточно.

Случай	Что показал эксперимент
Q01, исходный контекст	Во всех режимах статус entailed: время ограничения подтверждено журналом событий, но набор выбранных evidence ID различается
Q09, режим B	Ответ both: свидетельства о предупреждении расходятся; указаны доказательство C36 и контрдоказательство C37
Q05, удаление посылки, B	Статус стал insufficient, поскольку подтверждения временной связи после удаления факта не хватило
Q01, добавленное противоречие	Модель в нескольких режимах сохранила entailed вместо ожидаемого both и не учла новый конфликт

Мы не заменяли эти ответы ручной разметкой. Наоборот, сопоставили их с эталонами и сохранили как удачные и неудачные наблюдения модели. Особое внимание уделили Q09: наличие counterevidence_ids показывает, что для противоречия важно не просто написать слово both, а указать конфликтующие источники.

8. Итоги и ограничения

Мы увидели, что **поиск релевантных доказательств оказался важнее простого увеличения контекста**: BM25 сократил объём входа и улучшил результаты на нашей выборке. P-adic структура обеспечивает понятную группировку по происхождению и времени, но не дала устойчивого выигрыша по статусам. Наиболее сложными для модели оказались стресс-ситуации, когда исчезает обязательная посылка или добавляется противоречащий источник.

Работа ограничена одним вымышленным досье, 12 вопросами и одной моделью. Часть сравнений зависит от малых чисел наблюдений и повторов генерации даже при temperature=0. Мы рассматриваем результаты как исследование конкретного стенда, а не доказательство универсального превосходства BM25 или непригодности p-adic метода. Полные ответы, контексты и расчёты доступны в репозитории, поэтому выводы можно проверить независимо.